

UD05 - Big Data

Índice

- [1. Introducción al Big Data](#)
- [2. Ciclo de vida del dato](#)
- [3. Ciencia de datos \(Data Science\)](#)
- [4. Análisis de datos \(Data Analytics\)](#)
- [5. Almacenamiento de Big Data en la nube](#)
- [6. Aplicación del Big Data en los sectores productivos](#)

1. Introducción al Big Data

1.1. ¿Qué es el Big Data?

El término **Big Data** hace referencia a conjuntos de datos tan grandes y complejos (volumen) que las herramientas de software de procesamiento de datos tradicionales no pueden capturarlos, gestionarlos ni procesarlos en un tiempo razonable.

En el contexto de las Tecnologías Habilitadoras Digitales (THD), el Big Data actúa como un catalizador que permite procesar ingentes cantidades de información para identificar patrones, tendencias y relaciones ocultas que serían indetectables manualmente.

- **Definición:** conjuntos de datos tan extensos y complejos que requieren tecnologías y métodos de procesamiento avanzados, ya que las herramientas convencionales no pueden gestionarlos en un tiempo razonable.
- **Cambio de paradigma:** los datos se generan constantemente (transacciones, sensores, redes, navegación web). Big Data aporta infraestructura y técnicas para convertir ese flujo en información útil.
- **Habilitador de otras tecnologías:** sin grandes volúmenes de datos, tecnologías como la **Inteligencia Artificial** no podrían entrenar ni mejorar modelos de aprendizaje automático.

1.2. Diferencia entre dato e información

Para comprender el valor del Big Data es importante distinguir entre **materia prima (dato)** y **producto final (información)**:

- **Dato (materia prima):** representación simbólica de un atributo o variable. En la economía digital, los datos se comparan con el petróleo: son el recurso básico bruto.
- **Tipos de datos:**
 - **Estructurados:** organizados en tablas y bases de datos tradicionales (p. ej., hojas de cálculo, SQL).
 - **No estructurados:** sin formato predefinido (imágenes, vídeos, audio, texto libre, correos, publicaciones en redes).
 - **Semiestructurados:** formatos intermedios (XML, JSON).
- **Información (producto refinado):** resultado de procesar, limpiar y contextualizar datos para dotarlos de significado. Un dato aislado (p. ej., "25") no es útil; como información (p. ej., "25 °C en la sala de servidores") permite tomar decisiones.

Importante: sin datos de calidad, no hay información fiable (principio "Garbage in, garbage out").

1.3. Características del Big Data (las 5 V)

Las "5 V" describen la complejidad y el potencial de un escenario de Big Data:

1. **Volumen:** grandes cantidades de información (de GB a TB, PB o más) generadas continuamente.
2. **Velocidad:** ritmo al que se generan y procesan datos. El análisis debe ser casi en tiempo real.
3. **Variedad:** múltiples fuentes y formatos (texto, imágenes, logs, sensores, audio, vídeo).
4. **Veracidad:** fiabilidad y veracidad de los datos. Datos de calidad ("basura") llevan a decisiones erróneas; por eso la limpieza es crítica antes del análisis.
5. **Valor:** objetivo final: transformar datos en decisiones y mejoras medibles para la organización.

2. Ciclo de vida del dato

El dato no es un elemento estático, sino un activo dinámico que fluye a través de la organización. Desde el instante en que nace en un sensor o una aplicación hasta que finalmente se archiva o elimina, atraviesa una serie de etapas críticas. Gestionar correctamente este ciclo vital es lo que diferencia a una empresa que simplemente almacena "muchos datos" de una organización verdaderamente **data-driven**, capaz de extraer valor real de su información.

2.1. Fase 1: generación y recopilación (ingesta)

Todo comienza con la captura de la realidad. En esta primera fase, conocida como ingesta, la organización despliega sus redes para identificar y absorber información de todas las fuentes relevantes, creando un flujo constante de "materia prima" digital.

- **Fuentes internas corporativas:** Son los datos que la propia empresa genera en su operación diaria, provenientes de sistemas transaccionales como ERPs (planificación de recursos), CRMs (gestión de clientes) o los registros técnicos (logs) de sus servidores.
- **Fuentes externas y ecosistema IoT:** Gracias a la hiperconectividad, los sensores conectados actúan como los sentidos de la organización, capturando datos del mundo físico —como temperatura, ubicación GPS o vibraciones de maquinaria— y digitalizándolos en tiempo real.
- **Variedad de formatos:** La ingesta no discrimina; acepta datos estructurados en tablas, pero también debe manejar el caos de los datos no estructurados (vídeos, textos libres) y semiestructurados, integrándolos en un flujo común.

Ejemplo: Tesla no solo fabrica coches, sino que recopila millones de kilómetros de datos de conducción real de su flota para entrenar continuamente sus sistemas de asistencia y conducción autónoma.

2.2. Fase 2: preprocesamiento y limpieza (preparación)

Una vez capturados, nos enfrentamos a la realidad de que los datos en bruto (*raw data*) suelen ser imperfectos. Contienen errores, duplicados o huecos que, si no se tratan, contaminarían cualquier análisis posterior bajo el principio de "si entra basura, sale basura".

- **Limpieza y depuración:** Es el proceso higiénico fundamental consistente en detectar y eliminar registros corruptos, corregir imprecisiones obvias y unificar duplicados para asegurar una base sólida.

- **Normalización y estandarización:** Para poder comparar peras con manzanas, es necesario ajustar escalas y homogeneizar formatos (como fechas o divisas), permitiendo que datos de orígenes dispares hablen un idioma común.
- **Gestión de valores atípicos (outliers):** Requiere un análisis inteligente para discernir si un dato anómalo es un simple error de medición que debe descartarse o un evento extraordinario que contiene información valiosa de negocio.

Ejemplo: Plataformas como Airbnb depuran exhaustivamente los datos de sus reservas para evitar precios irreales o fraudes antes de alimentar sus modelos predictivos de precios.

2.3. Fase 3: almacenamiento y gestión

Con los datos limpios, el desafío se traslada a su conservación eficiente. El volumen masivo del Big Data ha dejado obsoletos los servidores locales tradicionales, impulsando la adopción de arquitecturas escalables y flexibles, mayoritariamente en la nube.

- **Data Lake (lago de datos):** Funciona como un vasto reservorio donde se vierten los datos en su estado natural o crudo. Es una opción económica y flexible, ideal para que los científicos de datos exploren sin las restricciones de una estructura rígida previa.
- **Data Warehouse (almacén de datos):** Representa la biblioteca ordenada de la empresa. Aquí se guardan los datos que ya han sido estructurados, procesados y refinados, listos para ser consumidos rápidamente en informes ejecutivos y consultas de negocio.
- **Infraestructura Cloud (pública/híbrida):** Servicios globales como AWS S3, Microsoft Azure o Google Cloud permiten a las empresas escalar su capacidad de almacenamiento de forma elástica, pagando solo por lo que usan y olvidándose de las limitaciones físicas del hardware.

2.4. Fase 4: análisis y modelado

Llegamos al corazón del proceso, el momento en que la "materia prima" almacenada se transforma en conocimiento mediante la aplicación de inteligencia matemática y algoritmos avanzados.

- **Entrenamiento de modelos de IA:** Se alimentan algoritmos de aprendizaje automático (*Machine Learning*) con grandes volúmenes de datos históricos, "enseñando" a la máquina a reconocer comportamientos y reglas complejas.
- **Descubrimiento de patrones ocultos:** Mediante técnicas de minería de datos, se sacan a la luz tendencias, correlaciones y causalidades que permanecían invisibles a la intuición humana o al análisis tradicional.
- **Iteración y mejora continua:** El modelado no es un evento único; los modelos deben ser reentrenados y ajustados periódicamente con nuevos datos para mantener su precisión y adaptarse a la realidad cambiante.

2.5. Fase 5: interpretación, visualización y uso

Para que el análisis tenga impacto, debe salir del laboratorio y llegar a los tomadores de decisiones. Esta fase se encarga de traducir la complejidad matemática a un lenguaje de negocio claro y accionable.

- **Visualización de datos:** El uso de herramientas de Business Intelligence (como Power BI o Tableau) y cuadros de mando interactivos convierte las filas de números en gráficos intuitivos que cuentan una historia visual comprensible de un vistazo.

- **Toma de decisiones informada:** Es el objetivo último: habilitar a directivos y empleados para que transformen las predicciones e indicadores en acciones concretas, como realizar un mantenimiento preventivo antes de una avería o lanzar una oferta personalizada.

2.6. Fase 6: gobernanza, archivado y borrado

Finalmente, el ciclo se cierra con la responsabilidad corporativa. Gestionar el dato implica también protegerlo, cumplir la ley y saber cuándo despedirse de él para mantener la eficiencia y la legalidad.

- **Privacidad y ética (Compliance):** Garantizar el cumplimiento estricto de normativas como el RGPD es innegociable, incluyendo procesos de anonimización y la gestión transparente del consentimiento de los usuarios.
- **Ciberseguridad y protección:** Implementar barreras robustas y protocolos de acceso para blindar la información estratégica frente a accesos no autorizados, fugas o ciberataques, que podrían ser devastadores.
- **Archivado o destrucción segura:** Cuando el dato pierde su utilidad inmediata pero debe conservarse por ley, se mueve a un almacenamiento "frío" y barato. Si ya no es necesario, se procede a su borrado seguro para reducir costes y riesgos legales.

3. Ciencia de datos (Data Science)

3.1. ¿Qué es la ciencia de datos?

La **ciencia de datos** es un campo interdisciplinar que utiliza métodos científicos, procesos y algoritmos para extraer conocimiento tanto de datos estructurados como no estructurados. No se trata de una disciplina aislada, sino de la intersección vital entre tres grandes áreas: las **matemáticas y estadística**, que aportan el rigor necesario para modelar, calcular probabilidades y encontrar patrones ocultos; las **ciencias de la computación**, que proveen la infraestructura y capacidad de programación para manejar grandes volúmenes de información; y el **conocimiento del negocio**, fundamental para formular las preguntas adecuadas e interpretar los resultados en un contexto que aporte valor real a la organización.

3.2. El ciclo de vida de un proyecto de datos

Un proyecto típico de ciencia de datos sigue un ciclo estructurado que consta de varias fases clave:

- **Definición del objetivo de negocio**
- **Recopilación y preparación de datos**
- **Selección y modelado**
- **Validación**
- **Interpretación y despliegue**

Todo proyecto de ciencia de datos comienza inevitablemente con una pregunta. La fase inicial es la **definición del objetivo de negocio**, donde se busca traducir un problema real (por ejemplo, detectar qué clientes tienen probabilidad de abandonar la compañía) en una pregunta analítica concreta.

Una vez claro el objetivo, comienza la etapa más laboriosa, a menudo consumiendo la mayor parte del tiempo del proyecto: la **recopilación y preparación** (*data wrangling*). En dicha fase se conectan las diversas fuentes de datos (bases de datos, APIs, sensores) y se realiza una limpieza exhaustiva para corregir errores, homogeneizar formatos y validar la calidad de la información.

Con los datos listos y depurados, se procede a la **selección y modelado**. En este punto, el equipo técnico elige los algoritmos más adecuados (regresión, clasificación, agrupamiento, etc.) y los "entrena" utilizando datos históricos para que aprendan a reconocer patrones.

Tras el entrenamiento, es crucial la fase de **validación**, donde se pone a prueba el modelo con datos nuevos que nunca ha visto antes para asegurar que sus predicciones son fiables y no fruto del azar.

Finalmente, el ciclo se cierra con la **interpretación y despliegue**, momento en el que los resultados matemáticos se traducen en acciones de negocio o se integran en sistemas de producción para automatizar la toma de decisiones.

3.3. Perfiles profesionales y herramientas del ecosistema

El tratamiento profesional de los datos requiere roles especializados que colaboran estrechamente como en una cadena de montaje digital. El **Ingeniero de Datos** (*Data Engineer*) actúa como el arquitecto que construye y mantiene la infraestructura y las "tuberías" por las que fluyen los datos, asegurando que la información llegue limpia, segura y accesible a los repositorios. Sobre esa base sólida trabaja el **Científico de Datos** (*Data Scientist*), un perfil con fuerte base matemática que aplica algoritmos avanzados y aprendizaje automático para construir modelos predictivos complejos. Complementando este trabajo se encuentra el **Analista de Datos** (*Data Analyst*), quien se enfoca en explorar la información histórica para responder preguntas de negocio inmediatas y comunicar los hallazgos mediante informes y visualizaciones claras.

Para llevar a cabo estas tareas, estos profesionales se apoyan mayoritariamente en lenguajes de programación versátiles como **Python** (con librerías especializadas como Pandas o Scikit-learn) y **R**, que se han convertido en el estándar de la industria. Además, cuando el volumen de datos es masivo, es imprescindible el uso de plataformas de procesamiento distribuido como **Apache Spark** o **Hadoop**, así como herramientas de entorno visual (como KNIME o RapidMiner) que facilitan el diseño de flujos de datos y el prototipado rápido de soluciones analíticas.

4. Análisis de datos (Data Analytics)

Si el Big Data es la acumulación masiva de información, el **análisis de datos** es el proceso de "interrogar" a esos datos para obtener respuestas. Sin análisis, los datos son solo ruido.

4.1. Niveles de análisis: del pasado al futuro

El análisis de datos no es un bloque monolítico, sino un proceso evolutivo que gana en complejidad y valor estratégico. Todo comienza con el **análisis descriptivo**, que mira por el retrovisor para responder a la pregunta *¿qué pasó?* mediante estadísticas, resúmenes e informes históricos. Una vez comprendido el pasado, las organizaciones maduras avanzan hacia el **análisis predictivo**, utilizando técnicas de aprendizaje automático para estimar probabilidades futuras y responder a *¿qué pasará?* (por ejemplo, estimando la demanda de stock). La cumbre de este proceso es el **análisis prescriptivo**, que va un paso más allá: no solo predice el futuro, sino que recomienda acciones concretas para optimizar los resultados, respondiendo a la pregunta crucial *¿qué deberíamos hacer?*.

4.2. Convergencia tecnológica

En la actualidad, estas disciplinas no operan en el vacío, sino que convergen para potenciar su impacto. El **Big Data** proporciona la infraestructura y la materia prima masiva; la **analítica y minería de datos** ofrecen las

técnicas para explorar y comprender esa información; y la **Inteligencia Artificial** aporta algoritmos capaces de aprender patrones complejos. Una analogía útil para entender esta simbiosis es imaginar un vehículo: el Big Data es el **combustible** necesario, la IA actúa como el **motor** que impulsa la decisión y la acción, y la analítica sirve como sistema de **navegación** que guía hacia la ruta más eficiente.

4.3. Visualización y herramientas

Para que los hallazgos matemáticos sean útiles, deben traducirse a un lenguaje visual comprensible para los humanos. La **visualización de datos** convierte números abstractos en **cuadros de mando** (*dashboards*) intuitivos, permitiendo a los directivos monitorizar métricas y alertas en tiempo real. Para ejecutar todo este flujo, el mercado ofrece un amplio espectro de herramientas: desde soluciones **visuales** (*low-code*) como Power BI, Tableau o KNIME, accesibles para perfiles de negocio, hasta entornos de **programación pura** en Python o R para análisis estadístico profundo, llegando a plataformas de **procesamiento distribuido** como Apache Spark cuando el volumen de datos es inmanejable para un servidor convencional.

5. Almacenamiento de Big Data en la nube

El almacenamiento es el cimiento del Big Data. Las soluciones tradicionales, basadas en servidores locales con capacidad limitada, han demostrado ser incapaces de escalar ante las exigencias de volumen y velocidad que imponen las "5 V".

5.1. La evolución del almacenamiento: del almacén al lago

Históricamente, las empresas centralizaban su información en el **Data Warehouse** (almacén de datos), un modelo diseñado para datos estructurados y procesados, ideal para generar informes de negocio consistentes pero muy rígido y costoso cuando se trata de información no estructurada. La irrupción del Big Data forzó la aparición del **Data Lake** (lago de datos), un repositorio mucho más flexible y económico que permite almacenar datos crudos en su formato nativo. Mientras que el almacén funciona como una tienda perfectamente ordenada donde todo está etiquetado, el lago actúa como un vasto reservorio de datos en bruto, listos para ser explorados por científicos de datos o utilizados para entrenar inteligencias artificiales.

5.2. El rol imprescindible de la nube

La computación en la nube (*cloud computing*) se ha convertido en el habilitador tecnológico por excelencia para este nuevo paradigma. Frente a la inversión inicial masiva en hardware (CAPEX), la nube ofrece un modelo de pago por uso (OPEX) que permite una **escalabilidad elástica**, creciendo o decreciendo en recursos según la demanda del momento. Además, proveedores como AWS, Azure o Google Cloud garantizan la seguridad y la redundancia de la información mediante la replicación geográfica, protegiendo los datos contra fallos físicos o desastres locales de una forma que sería inviable para un centro de datos corporativo tradicional.

5.3. Nuevas bases de datos y sistemas distribuidos

Para gestionar la variedad y velocidad extremas, el modelo relacional clásico (SQL) a menudo resulta insuficiente debido a su esquema fijo. Por ello, han proliferado las bases de datos **NoSQL**, que ofrecen esquemas flexibles y un altísimo rendimiento para la lectura y escritura masiva, siendo ideales para documentos, grafos o series temporales. Paralelamente, cuando los conjuntos de datos superan la capacidad de un único equipo, entran en juego los **sistemas de archivos distribuidos** como HDFS (Hadoop). Esta

tecnología fragmenta los archivos gigantes en bloques y los reparte entre múltiples nodos de un clúster, permitiendo el procesamiento en paralelo y reduciendo drásticamente los tiempos de análisis.

6. Aplicación del Big Data en los sectores productivos

El objetivo final de implantar Big Data no es tecnológico, sino de negocio. Se trata de evolucionar de una cultura basada en la intuición a una organización **data-driven**, donde las decisiones se fundamentan en evidencias cuantificables.

6.1. Objetivos estratégicos en la empresa

La adopción de estas tecnologías persigue metas transversales claras. En primer lugar, busca **reducir costes** mediante la identificación de ineficiencias y desperdicios ocultos en los procesos. Simultáneamente, pretende agilizar la **toma de decisiones**, sustituyendo los informes retrospectivos por tableros de control en tiempo real. Hacia el exterior, el análisis de datos permite un conocimiento profundo del cliente (visión "Customer 360"), entendiendo sus motivaciones para ofrecer **productos y servicios personalizados** que antes eran inimaginables, generando así nuevas fuentes de ingresos.

6.2. Transformación sectorial

El impacto del Big Data es visible en todos los verticales de la economía. En la **Industria 4.0**, el mantenimiento predictivo anticipa fallos de maquinaria analizando vibraciones y temperaturas, mientras que los gemelos digitales simulan escenarios productivos sin riesgo físico. El sector **Retail** utiliza algoritmos para recomendar productos, ajustar precios dinámicamente según la competencia y optimizar el stock de cada tienda prediciendo tallas y modelos. En **Logística**, la optimización de rutas cruza datos de tráfico y clima para ahorrar combustible, y en el sector agroalimentario (**Smart Agro**), la agricultura de precisión aplica agua y fertilizantes solo donde los sensores indican necesidad. Finalmente, la **Banca** (Fintech) emplea estas técnicas masivas para detectar fraudes en milisegundos y evaluar riesgos crediticios con mayor precisión.

6.3. Sostenibilidad y ética

Más allá de la rentabilidad, el Big Data es un aliado clave para la **sostenibilidad**. Las redes eléctricas inteligentes (*smart grids*) ajustan la producción al consumo real para eficiencia energética, y la predicción de demanda en alimentación reduce drásticamente el desperdicio de productos perecederos. Sin embargo, este poder conlleva una gran responsabilidad ética. El uso masivo de datos personales plantea retos críticos en **privacidad** y cumplimiento normativo (RGPD), así como el riesgo de **sesgos algorítmicos** que pueden discriminar colectivos si los datos de entrenamiento no son neutrales. Además, la concentración de tanta información convierte a estas bases de datos en objetivos prioritarios para ciberataques, haciendo de la seguridad un pilar innegociable.

Reflexión: Big Data es una herramienta potente; su impacto depende de un uso ético, seguro y alineado con objetivos reales.